# Analyse lexicale

# Cyril Rabat cyril.rabat@univ-reims.fr

Licence 3 Informatique - Info0602 - Langages et compilation

2019-2020





#### Cours n°2

Qu'est-ce qu'un analyseur lexical? Langages, expressions régulières, automates finis


Version 8 janvier 2020

### Table des matières

- 2 L'analyse lexicale
  - Un analyseur lexical
  - Les langages
  - Les expressions régulières
  - Les automates finis
  - De l'expression régulière à un AFN
  - Transformation d'un AFN en AFD

# Un analyseur lexical

- Lecture des caractères en entrée
- Production d'unités lexicales
  - → Analysées par l'analyseur syntaxique
- Interaction entre les deux analyseurs



### Tâches secondaires

- Élimination...
  - Des commentaires
  - Des caractères "inutiles" (espaces, tabulations, lignes vides...)
- Faciliter la gestion des erreurs :
  - Conservation/calcul du numéro de ligne
  - Associer les messages d'erreur à une ligne
- Principal intérêt de l'analyseur lexical :
  - ⇔ Simplification de l'analyseur syntaxique

# Unité lexicale. modèle, lexème et attribut

- Modèle : règle qui décrit un ensemble de chaînes
- Unité lexicale : produite par l'ensemble de chaînes du modèle chaînes littérales
- Lexème : la suite de caractères du programme source qui correspond au modèle

#### Exemple

- Unité lexicale : chiffre
- Lexèmes : 0, 1, 2
- Modèle : [0 − 9]
- Attributs : données liées aux unités lexicales

# Alphabet et mots

### Définition : alphabet

Un **alphabet** est un ensemble fini de symboles appelés caractères. Il est noté A.

- Exemples de symboles : lettres et caractères
- Exemples d'alphabets : {0,1} (l'alphabet binaire), l'ASCII

## Définition : mot (ou chaîne)

Un **mot** sur un alphabet est une séquence finie de symboles de cet alphabet. La longueur du mot w (notée |w|) est le nombre de symboles dans ce mot. Le mot vide, noté  $\epsilon$ , est un mot de longueur 0.

• Exemples de mots sur l'alphabet  $\{a, b, c\}$  : a, baba

### Partie de mots

- Préfixe de w : mot obtenu en supprimant un nombre quelconque de symboles en fin de w (voire aucun)
- Suffixe de w : mot obtenu en supprimant un nombre quelconque de symboles en début de w (voire aucun)
- Sous-mot de w : mot obtenu en supprimant un préfixe et un suffixe de w
- Préfixe propre de w : tout mot non vide x, préfixe de w tel que  $x \neq w$
- Idem pour suffixe propre et sous-chaîne propre de w
- Sous-suite de w : tout mot obtenu en supprimant un nombre quelconque de symboles de w, éventuellement aucun, pas nécessairement consécutifs

# Opérations sur les mots

- Concaténation de mots : si x et y sont des mots, la concaténation xy est la chaîne formée en joignant x et y
  - $\hookrightarrow$  Exemple : pour  $\mathcal{A} = \{a, b\}$ , si x = aa et y = bb, alors xy = aabb
- Exponentiation :  $s^0 = \epsilon$  ;  $s^i = s^{i-1}s$ 
  - $\hookrightarrow$  Exemple : pour  $\mathcal{A} = \{a, b\}$ , si x = ba alors  $x^3 = bababa$

### Définition : langage

Un langage est un ensemble de mots définis sur un même alphabet.

- Soit  $\mathcal{A} = \{1, 2, 3\}$ , l'ensemble  $\{1, 11, 12, 21\}$  est un langage sur  $\mathcal{A}$
- Le langage vide est noté ∅
- Le langage  $\{\epsilon\}$  ne contient que le mot vide

#### Attention

$$\emptyset \neq \{\epsilon\}$$

# Opérations sur les langages (1/2)

Soit deux langages  $L_1$  et  $L_2$  définis respectivement sur les alphabets  $A_1$  et  $A_2$ .

### Définition : union de deux langages

L'union de  $L_1$  et  $L_2$  définie sur  $A_1 \cup A_2$  est le langage contenant tous les mots de  $L_1$  et  $L_2$ :

$$L_1 \cup L_2 = \{ w \mid w \in L_1 \lor w \in L_2 \}$$

### Définition: intersection de deux langages

L'intersection de  $L_1$  et  $L_2$  définie sur  $A_1 \cap A_2$  est le langage contenant tous les mots qui sont à la fois dans  $L_1$  et  $L_2$ :

$$L_1 \cap L_2 = \{ w \mid w \in L_1 \land w \in L_2 \}$$

# Opérations sur les langages (2/2)

### Définition : complément d'un langage

Le complément de  $L_1$  est le langage défini sur  $\mathcal{A}_1$  contenant tous les mots qui ne sont pas dans  $L_1$ :

$$\mathcal{C}(L_1) = \{ w \mid w \in \mathcal{A}_1 \land w \notin L_1 \}$$

### Définition : différence de deux langages

La différence de  $L_1$  et  $L_2$  est le langage défini sur  $A_1$  contenant tous les mots de  $L_1$  qui ne sont pas dans  $L_2$ :

$$L_1 - L_2 = \{ w \mid w \in L_1 \land w \notin L_2 \}$$

# Produit et puissances

### Définition : produit de deux langages

Le produit ou **concaténation** de  $L_1$  et  $L_2$  est le langage défini sur  $A_1 \cup A_2$  contenant tous les mots formés d'un mot de  $L_1$  suivi d'un mot de  $L_2$ :

$$L_1.L_2 = \{w_1w_2 \mid w_1 \in L_1 \land w_2 \in L_2\}$$

# Définition: puissances d'un langage

Les puissances successives de  $L_1$  définies sur  $A_1$  sont définies récursivement:

- $L_1^0 = \{\epsilon\}$
- $L_1^n = L_1.L_1^{n-1}$  pour  $n \ge 1$

#### Fermeture itérative

### Définition : fermeture de Kleene de deux langages

La fermeture de Kleene de L<sub>1</sub>, appelée également la **fermeture itérative**, définie sur  $A_1$ , est l'ensemble des mots formés par une concaténation finie des mots de L<sub>1</sub> :

$$L_1^* = \{ w \mid \exists k \geq 0 \land w_1 \dots w_k \in L_1 \text{ tels que } w = w_1 w_2 \dots w_k \}$$

• On définit également  $L_1^+$ :  $L_1^+ = \{ w \mid \exists k > 0 \land w_1 \dots w_k \in L \text{ tels que } w = w_1 w_2 \dots w_k \}$ 

# Langage fini et infini

### Définition : langage fini

Un langage fini peut être décrit par l'énumération des mots qui le compose. Ce qui n'est pas le cas pour un langage infini.

- Certains langages infinis peuvent être décrits à l'aide d'opérations sur des langages simples
- Certains langages infinis peuvent être décrits à l'aide de règles (grammaires)
- Les langages qui ne peuvent être décrits ni par des opérations, ni par des grammaires sont des langages indécidables.

# Expressions régulières

### Définition : expression régulière

Les expressions régulières pour un alphabet  ${\mathcal A}$  sont les expressions formées par les règles suivantes :

- ullet  $\emptyset$ ,  $\epsilon$  et les symboles de  ${\mathcal A}$  sont des expressions régulières
- Si  $\alpha$  et  $\beta$  sont des expressions régulières sur  $\mathcal{A}$ ,  $(\alpha|\beta)$ ,  $(\alpha.\beta)$  et  $(\alpha)^*$  sont des expressions régulières
- On note indifféremment  $\alpha.\beta$  et  $\alpha\beta$
- On définit une priorité décroissante sur les opérateurs : \*, . et |

# Langage décrit par une expression régulière

### Définition : langage décrit par une expression régulière

Le langage L(E) où E est une expression régulière définie sur A, est défini comme suit :

- $L(E) = \emptyset$  si  $E = \emptyset$
- $L(E) = \{\epsilon\}$  si  $E = \epsilon$
- $L(E) = \{a\}$  si E = a pour tout  $a \in A$
- $L(E) = L(E_1) \cup L(E_2)$  si  $E = E_1 | E_2$
- $L(E) = L(E_1).L(E_2)$  si  $E = E_1.E_2$
- $L(E) = L(E)^*$  si  $E = E_1^*$

### Introduction

- Expression régulière : définie un ensemble de mots
- Nécessité de les compiler pour créer un programme qui la reconnait
- But du programme :
  - Entrée : le mot à reconnaître
  - Sortie : oui ou non suivant si le mot est reconnu par l'expression régulière
- Utilisation d'automates

### Présentation des automates

### Un automate fini se compose :

- D'un ruban d'entrée :
  - Constitué d'un ensemble de cases, chacune contenant un caractère
  - Le mot à traiter est placé dans ces cases
  - Une tête de lecture permet de connaître le caractère suivant
- D'un ensemble d'états :
  - L'automate passe d'un état à l'autre en cours d'exécution
  - L'état initial : état en début d'exécution
  - Les états d'acceptation (ou états finals) : états atteints lorsque le mot est accepté
- D'une fonction de transition :
  - Indique pour chaque état et symbole lu, le prochain état

### Automates finis déterministes vs non déterministes

- Dans un état donné et pour un symbole donné
- Deux possibilités lorsqu'un symbole est rencontré :
  - Une seule transition possible :
  - Plusieurs transitions possibles :

### Remarque

Des définitions plus formelles sont présentées dans la suite!

### Automate fini déterministe

#### Définition : automate fini déterministe

Un automate fini déterministe (noté AFD) est défini formellement par le quintuplet  $M = \{Q, A, \delta, s, F\}$ , où :

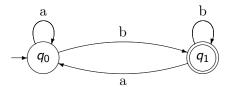
- Q est un ensemble fini d'états
- A est un alphabet
- $\delta$  est la fonction de transition de  $Q \times A$  dans Q
- $s \in Q$  est l'état initial
- F ⊂ Q est l'ensemble des états d'acceptation

# Représentation d'un automate fini par un graphe

- Chaque état de l'automate est représenté par un nœud du graphe
- Relation de transition représentée par des arcs valués :  $\hookrightarrow$  Si  $\delta(q, a) = q', (q, q') \in Q^2 \land a \in \mathcal{A}$  alors il existe un arc a entre les sommets q et q'
- L'état initial est signalé par une flèche
- Les états d'acceptation sont signalés par des doubles cercles

# Exemple de représentation

Soit l'automate  $M = \{Q, A, \delta, s, F\}$  suivant :



### Exécution d'un automate

#### Définition : configuration d'un AFD

Une configuration d'un AFD est une paire composée de l'état de l'automate, ainsi que la partie du mot restant à traiter :

$$(q, w) \in Q \times A^*$$

- Exécution d'un automate : déterminer les configurations successives de l'automate en fonction du mot d'entrée
- Dérivation : le passage d'une configuration à une autre

# Dérivation (1/2)

#### Définition : dérivation (en une étape)

La configuration (g', w') est dérivable en une étape de (g, w) par M si :

- w = aw' ( $a \in A$ , a est le premier caractère de w et w' est égal à w privé de a)
- $q' = \delta(q, a)$  (q' est le prochain état déterminé par la fonction de transition  $\delta$  pour q et a)

On note  $(q, w) \vdash_M (q', w')$ 

# Dérivation (2/2)

### Définition : dérivation (en plusieurs étapes)

La configuration (q', w') est dérivable (en plusieurs étapes) de (q, w)s'il existe  $k \ge 0$  et des configurations  $(q_i, w_i), 0 \le i \le k$  telles que :

- $\bullet$   $(a_0, w_0) = (a, w), (a_k, w_k) = (a', w')$
- $\forall i \in [0, k], (q_i, w_i) \vdash_M (q_{i+1}, w_{i+1})$

On note  $(q, w) \vdash_{M}^{*} (q', w')$ 

- Exécution d'un automate (si le mot est accepté) :  $(s, w) \vdash (q_1, w_1) \vdash \ldots \vdash (q_n, \epsilon)$
- s est l'état initial,  $\epsilon$  le mot vide et n = |w|

### Une seule exécution possible pour chaque mot

# Acceptation

### Définition: acceptation

Un mot est accepté par un automate M si le dernier état est un état d'acceptation :

w est accepté par 
$$M$$
 si  $(s,w) \vdash_{M}^{*} (q,\epsilon) \land q \in F$ 

Le langage accepté par M (noté L(M)) est défini par l'ensemble des mots acceptés par M :

$$L(M) = \{ w \in \mathcal{A}^* \mid (s, w) \vdash_M^* (q, \epsilon) \land q \in F \}$$

# Simulation du comportement d'un AFD

```
Fonction simulationAFD(Q, A, \delta, s, F, w) : booléen
    etat \leftarrow s
     position \leftarrow 0
    erreur \leftarrow faux
     Tant que!erreur \land position < |w| Faire
        Si w[position] \notin A Alors
          erreur ← vrai
        Sinon
          Si \exists \delta(etat, w[position]) Alors
              etat \leftarrow \delta(etat, w[position])
              position \leftarrow position + 1
          Sinon
              erreur ← vrai
     retourner \leftarrow !erreur \land etat \in F
```

### Les automates finis non déterministes

#### Automates où les constructions suivantes sont autorisées :

- Plusieurs transitions sur le même symbole partant d'un même état
- Transitions sur le mot vide acceptées
- Transitions sur des mots de longueur supérieure à 1 sont possibles

### Remarque

Les automates finis non déterministes sont généralement plus faciles à écrire que les AFD mais moins rapides à simuler.


### Automate fini non déterministe

#### Définition : automate fini non déterministe

Un automate fini non déterministe (noté AFN) est défini formellement par le quintuplet  $M = \{Q, A, \Delta, s, F\}$ , où :

- Q est un ensemble fini d'états
- A est un alphabet
- $\Delta$  est la fonction de transition de  $Q \times \mathcal{A}^*$  dans Q
- $s \in Q$  est l'état initial
- F ⊂ Q est l'ensemble des états d'acceptation

# Exemple d'AFN



### Dérivation d'un AFN


### Définition : dérivation (en une étape)

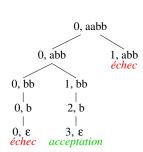
La configuration (q', w') est dérivable en une étape de (q, w) par M si :

- $w = uw' \ (u \in \mathcal{A}^*)$
- $(q, u, q') \in \Delta$  (le triplet (q, u, q') est un élément de la relation de transition)
- Acceptation d'un mot par un AFN : il existe une dérivation qui accepte ce mot
  - → Des dérivations possibles peuvent le refuser!
- Construction plus simple que les AFD mais sans forcément reconnaître plus de langages

Problème : plusieurs dérivations possibles pour un même mot !

- Vérifier si l'une d'elles permet d'accepter le mot
- Être en mesure de revenir en arrière (backtrack)
- → Utilisation de la récursivité





# Simulation d'un AFN (2/2)

```
Fonction simulationAFN(M, etat, w, position) : booléen
    Si position \geq |w| Alors
       retourner etat \in M(F)
    Sinon
       accepte \leftarrow faux
       couples \leftarrow M(\Delta)(etat, w)
       Tant que couples \neq \emptyset \land !accepte Faire
          choisir (e', I) \in \text{couples}
          couples \leftarrow couples \setminus (e', I)
          accepte \leftarrow simulationAFN(M, e', w, p + l)
       retourner accepte
```

### Remarques


M est l'automate et w le mot à reconnaître Fonction exécutée avec etat = s et position = 0

#### Construction de Thomson

- Objectif : construire de manière automatique un AFN à partir de toute expression régulière
- Idée :
  - Décomposition de l'expression régulière en sous-expressions
  - Construction d'un AFN pour chaque sous-expression
  - Combinaison des AFN

# Règles de base

• Règle n°1 : pour l'expression  $\epsilon$ , nous construisons l'AFN suivant :




• Règle n°2 : pour l'expression  $a \in A$ , nous construisons l'AFN suivant :




# Combinaisons (1/2)

Supposons que  $N(E_1)$  et  $N(E_2)$  sont des AFN pour les expressions régulières  $E_1$  et  $E_2$ .

• Combinaison n°1 : pour l'expression  $E_1|E_2$ 

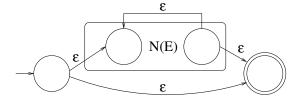


• Combinaison n°2 : pour l'expression  $E_1.E_2$ 



# Combinaisons (2/2)


• Combinaison n°3 : pour l'expression E\*



• Combinaison n°4 : pour l'expression (E), c'est N(E) lui-même

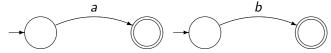
# Exemple (1/4)

- Supposons l'expression régulière (a|b)\*abb




# Exemple (2/4)


• Pour  $E_1 = E_6 = a$  et  $E_2 = E_8 = E_{10} = b$ :



• Pour  $E_3 = E_1 | E_2$ :




- Pour  $E_4 = (E_3)$ , c'est  $E_3$  lui-même
- Pour  $E_5 = E_3^*$ :



# Exemple (4/4)

• Pour finir en combinant avec  $E_7$ ,  $E_9$  et  $E_{11}$ 



# Équivalence entre un AFN et un AFD

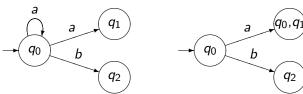
### Définition : équivalence entre un AFN et un AFD

Un AFD est équivalent à un AFN s'il accepte le même langage.

• Exemple 1:



• Exemple 2:



# Définition d'opérations sur un AFN

#### Définition : $\epsilon$ -fermeture d'un état

Soit l'AFN  $M = \{Q, A, \Delta, s, F\}$  et  $e \subset Q$ ,  $\epsilon$ -fermeture(e) est l'ensemble des états de M accessibles depuis e par des  $\epsilon$ -transitions uniquement.  $e \in \epsilon$ -fermeture(e).

#### Définition : $\epsilon$ -fermeture d'un ensemble d'états

Soit l'AFN  $M = \{Q, A, \Delta, s, F\}$  et  $T \subset Q$ ,  $\epsilon$ -fermeture(T) est l'ensemble des états de M accessibles depuis tout  $e \in T$  par des  $\epsilon$ -transitions uniquement.  $T \subseteq \epsilon$ -fermeture(T).

#### Définition: transiter

Soit l'AFN  $M=\{Q,\mathcal{A},\Delta,s,F\}$ ,  $T\subset Q$  et  $a\in\mathcal{A}$ , transiter(T,a) est l'ensemble des états de M tels qu'il existe une transition sur a à partir d'un  $e\in T$ . Si transiter(T,a)=T' alors on note  $T\stackrel{a}{\to} T'$ 


# Principes de la transformation

- Soit l'AFN  $M = \{Q, A, \Delta, s, F\}$
- Construction de l'AFD  $M' = \{Q', A, \delta, s', F'\}$
- Chaque état de l'AFD = ensemble d'états de l'AFN
- Construction d'un ensemble V (états à visiter) :
  - $\hookrightarrow$  Au départ,  $V = \{ \epsilon \text{-fermeture}(s) \}$
- Pour chaque état q de V :
  - $\hookrightarrow$  Ajout de q à Q' et retrait de q de V
  - $\hookrightarrow$  Pour chaque  $a \in \mathcal{A}$ , calcul de  $q' = \epsilon$ -fermeture(transiter(q,a))
  - $\hookrightarrow$  Ajout de q' dans V si  $q' \notin Q'$
- F est formé par tous les états de M' contenant un  $q \in F$

# Algorithme de transformation AFN en AFD

```
Fonction AFNversAFD(M) : M'
   s' \leftarrow \epsilon-fermeture(s)
   Q' \leftarrow \{s'\}; \delta = \emptyset; V \leftarrow \{s'\}
   Tant que \exists x \in V Faire
       V \leftarrow V \backslash x
       Pour tout a \in A Faire
           v \leftarrow \epsilon-fermeture(transiter(x, a)
           Si v \notin Q' Alors
              Q' \leftarrow Q' \cup v
               V \leftarrow V \cup v
          \delta \leftarrow \delta \cup \{(x, v, a)\}
       Fin Pour
   F' \leftarrow \{x \in Q' \mid \exists f \in x \land f \in F\}
```

# Exemple (1/2)



X	transiter	у	δ
$s'=A=\{0,1,2,4,7\}$	$A \stackrel{a}{\rightarrow} \{3,8\}$	${3,8,6,1,7,2,4} = B$	$A \stackrel{a}{\rightarrow} B$
	$A \stackrel{b}{\rightarrow} \{5\}$	$\{5,6,7,1,2,4\} = C$	$A \stackrel{b}{\rightarrow} C$
$B = \{1,2,3,4,6,7,8\}$	$B \stackrel{a}{ o} \{3,8\}$		$B \stackrel{a}{\rightarrow} B$
	$B \stackrel{b}{ o} \{5,9\}$	{5,9,6,7,1,2,4}=D	$B \stackrel{b}{\to} D$
$C = \{1,2,4,5,6,7\}$	$C \stackrel{a}{ o} \{3,8\}$		$C \stackrel{a}{\rightarrow} B$
	$C \stackrel{b}{\rightarrow} \{5\}$		$C \stackrel{b}{\rightarrow} C$
$D=\{1,2,4,5,6,7,9\}$	$D \stackrel{a}{ o} \{3,8\}$		$D \stackrel{a}{ o} B$
	$D \stackrel{b}{ o} \{5,10\}$	{5,6,1,2,4,7,10}=E	$D \stackrel{b}{\to} E$
$E=\{1,2,4,5,6,7,10\}$	$E \stackrel{a}{\to} \{3,8\}$		$E \overset{\mathit{a}}{\to} B$
	$E \stackrel{b}{ o} \{5\}$		$E \stackrel{b}{\to} C$

# Exemple (2/2)

Sachant que seul E contient un état d'acceptation,  $E \in Q'$ . On obtient :

